

Decathlon VOC Analyzer: 面向商品图文证据与用户评论对齐的证据驱动多模态 VOC 分析系统

Severin Ye¹

*School of Computer Science and Engineering
Kyungpook National University
Daegu, Republic of Korea
6severin9@gmail.com*

Dokeun Lee²

*Department of Physics
Kyungpook National University
Daegu, Republic of Korea
nsa08008@naver.com*

Wushuang Liu²

*Department of Child Studies
Kyungpook National University
Daegu, Republic of Korea
824309203q@gmail.com*

Seowan Jung²

*School of Computer Science and
Engineering
Kyungpook National University
Daegu, Republic of Korea
swan041014@gmail.com*

HyunJun Jung²

*School of Computer Science and
Engineering
Kyungpook National University
Daegu, Republic of Korea
beanbeansummon@naver.com*

Hye Jeon²

*School of Computer Science and
Engineering
Kyungpook National University
Daegu, Republic of Korea
prajna0426@naver.com*

Abstract

电子商务 VOC (Voice of Customer) 分析需要同时理解评论中包含的主观用户体验与商品页面中的客观证据。本文提出 Decathlon VOC Analyzer, 这是一种将商品图像、商品文本与用户评论显式对齐的证据驱动多模态 VOC 分析系统。该系统将商品信息标准化为证据包, 保留带评分的原始评论, 并通过星级感知抽样与低信息评论过滤构建方面级 VOC 对象。随后, 系统将每个方面规划为用于文本支持、视觉确认和跨模态消解的问题, 沿文本与图像路径分别检索并重排序候选证据, 最终生成包含 **claim** 级证据归因与 **evidence gap** 的结构化报告。当前实现保留关键中间产物, 以支持可复现性、错误定位和后续 **replay** 分析, 并通过 166 项自动化测试验证了核心工作流的稳定性。

0.1 关键词

多模态 VOC 分析; 证据约束生成; 图文检索; 商品评论挖掘; 主张归因

1 I. 引言

用户评论分析是智能电商运营中的基础任务。既有研究主要聚焦于情感分类、主题聚类与基于方面的情感分析, 用于概括用户对商品属性所表达的正向或负向态度。然而, 这些评论意见能否被商品本身的证据解释、支持或反驳, 仍然相对缺乏研究。

从商品运营与产品改进的角度看, 仅仅知道“用户抱怨容量太小”并不足够。分析者还需要进一步确认: 商品页面是否清楚说明了尺寸信息, 图片是否展示了空间结构, 以及该问题究竟来自商品缺陷, 还是来自用户预期差异。

大语言模型为商品评论摘要带来了新的可能, 但单阶段摘要仍然存在局限。如果把商品文案、图片说明和全部评论直接输入模型, 虽然可以生成流畅的结果, 但很难审查这些结论究竟基于哪些评论和哪些商品证据。同时, 也难以判断错误究竟发生在评论理解、检索、证据解释, 还是最终生成阶段。

进一步看, 现有商品评论分析方法大多停留在情感统计、主题聚类、方面情感对抽取或黑盒式摘要层面。此类方法能够提供对用户态度的整体概括, 但通常较少处理评论观点与商品证据之间的对应关系, 也

较少区分产品缺陷、页面表达不足与用户预期偏差等不同来源。此外，若评论抽样策略缺乏约束，高评分或低信息评论容易占据有限分析预算，从而削弱系统对改进相关问题的表征能力。

因此，商品 VOC (Voice of Customer) 分析不应被视为黑盒摘要任务，而应被建模为一条从评论需求通向商品证据的可追踪流程。本文提出 **Decathlon VOC Analyzer**，用于将用户评论中的主观体验与商品文案和商品图像中的可验证证据进行对齐。在方法设计上，该系统具有三个相互衔接的特征。其一，系统将评论建模、问题规划、证据检索和报告生成组织为可追踪的多阶段流程，以支持中间产物复用与错误定位。其二，系统保留带评分的原始评论，并通过星级感知抽样优先覆盖诊断价值更高的低星级反馈，使评论建模更贴近产品改进场景。其三，系统将评论方面与商品文本、商品图像和局部视觉区域联合检索，并在最终报告中保留 **claim** 级证据归因与 **evidence gap**，从而提高分析结果的可审查性、可复现性和可操作性。

图 1 给出了本文系统的整体框架。系统从商品证据构建出发，将商品文本、图像、局部视觉区域和评论保留为可复用的证据对象；随后通过带评分评论保留、星级感知采样与方面抽取形成 VOC 方面对象，再将其转化为带有明确路径约束的检索问题，并最终生成带有 **claim** 级证据归因与 **evidence gap** 的结构化报告。

2 II. 提出系统

3 整体结构

所提系统由四个阶段组成，用于将用户评论中的主观 VOC (Voice of Customer) 信号与商品图像和文本证据连接起来。

第一，商品证据构建阶段将商品页面中的标题、描述、规格、图像、图像区域和评论整理为统一的证据对象。第二，VOC 方面建模阶段从评论中抽取包含属性、情感、观点、原文依据和使用场景的方面对象。第三，基于问题的多模态检索阶段将每个方面对象转换为用于文本支持、视觉确认和跨模态消解的检索问题，并从商品文本和商品图像中检索候选证据。第四，报告生成阶段基于检索到的证据生成包含优势、弱点、改进建议和证据空白的结构化报告，并将每个 **claim** 连接到评论证据、商品文本证据和商品图像证据。

维度	传统评论摘要/ABSA	本文系统
输出目标	情感标签、主题或整段总结	带证据归因的结构化 VOC 报告
商品证据接入	通常弱或缺失	文本、图像、局部视觉区域联合接入
评论处理	常按总体统计或直接汇总	保留评分并优先建模问题评论
可追踪性	难以定位错误来源	中间产物、 claim attribution 、 replay 可追踪

这一结构将检索增强生成 (Retrieval-Augmented Generation, RAG) 与图文检索的设计原理应用到商品 VOC 分析中 [1, 2]。与单阶段摘要方法不同，所提系统将评论方面抽取、问题规划、证据检索和报告生成等中间过程分离并保存下来。这样可以追踪最终报告中的某个结论究竟来自哪些评论与商品证据，也能相对清晰地判断错误发生在哪个阶段。由此，系统输出不再局限于摘要性结论，而是进一步保留评论观点与商品证据之间的对应关系，以及证据不足时的空白状态。

表 1 从处理对象、证据接入方式与结果表示三个方面概括了本文系统的结构特征。

系统整体流程已在图 1 中给出，下面按四个阶段对关键设计展开说明。商品证据层将商品文本、图像、局部视觉区域和评论保留为可复用的证据对象，并为文本块、图像、图像区域和评论分配稳定标识符，以支持后续索引、缓存和归因。VOC 方面建模层首先保留带评分的原始评论，再在有限计算预算下执行星级感知采样。当前默认 **profile** 为 **problem_first**，对 1 星至 5 星评论分别赋予 30%、25%、20%、15% 和 10% 的目标配额；当低星样本不足时，再按 **fallback** 顺序补位。与此同时，系统会过滤空评论、过短评论以及 **ok**、**good** 等低信息短评，以提升评论样本的诊断价值。基于问题的多模态检索层将评论方面转化为检索意图与路径都明确的问题。最后，报告层将最终的 **claim** 反向链接到评论证据、商品文本证据和商品图像证据。




Figure 1: Decathlon VOC Analyzer 的总体框架。系统以商品证据包和评论方面为中间表示，通过问题规划连接主观 VOC 信号与多模态商品证据，并在报告阶段进行 claim 级归因。

3.1 基于问题规划的多模态检索

所提系统不直接把原始评论句子当作检索查询。由于评论语句高度依赖上下文且表达不稳定，即使是同一类抱怨，也可能以“太小了”“收纳不足”“文件放不进去”等不同方式出现。因此，系统首先将评论方面拆解为三种证据意图：显式文本支持、视觉确认和跨模态消解 [3]。

文本支持问题用于确认商品描述与规格是否支持评论意见。视觉确认问题用于检查商品图像是否展示了相关结构或外观。跨模态消解问题用于判断文本与图像是否给出了同样的解释。这种做法将评论表述转化为可验证的问题表示，从而降低直接用评论原句检索所带来的表达漂移问题，并提高证据命中率与结果可解释性。与此同时，系统在问题规划阶段显式保留文本路径与图像路径，为后续的分路召回和分路重排提供约束 [4]。

图 2 展示了从评论方面到证据查询的问题规划过程。比如，“对于 travel documents 来说太小了”这样的评论，会被转换成一个包含尺寸方面、负面情感、使用场景和原文证据片段的方面对象。随后，系统分别生成问题，用于判断商品描述或规格中是否明确写出了尺寸限制、图像中是否能看到主要收纳空间，以及文本与图像是否对收纳容量提供了一致的依据。这里的关键不只是生成多个问题，而是让每个问

题都带有明确的证据路由与期望支持类型，从而把后续检索结果和最终报告 claim 精确对应起来。

3.2 证据评分与重排序

为了对评论方面与候选证据之间的相关性进行一致比较，所提系统使用结合文本相关性、图像相关性和跨模态一致性的证据评分。设评论方面为 a ，候选证据为 e ，则证据评分定义如公式 (1) 所示。

$$S(a, e) = \lambda_t R_t(a, e) + \lambda_v R_v(a, e) + \lambda_c C(a, e) \quad (1)$$

在公式 (1) 中， $R_t(a, e)$ 表示文本路径的相关性， $R_v(a, e)$ 表示图像路径的相关性， $C(a, e)$ 表示评论方面与商品证据之间的跨模态一致性约束。 λ_t 、 λ_v 、 λ_c 为可调权重。该公式并不是用于直接生成最终分析结果，而是为检索与重排序阶段提供统一的候选证据选择标准。其意义在于避免系统只根据单一路径分数做判断，从而减少“文本似乎相关但图像不支持”或“图像看似吻合但商品说明并未承诺”的错误归因。

所提系统首先分别从文本路径和图像路径召回候选证据，然后依据公式 (1) 对候选进行重排序。文本路径主要用于检查商品名称、类别、描述、规格和显式承诺等文档信息。图像路径主要用于检查商品的结




Figure 2: 评论方面到证据查询的规划机制。方面对象并不直接进入检索，而是先被分解为具有不同证据意图的问题，再分别触发文本路线、图像路线或图文联合路线。

构、外观、颜色、收纳形态以及开口方式、连接件和材质纹理等常由局部部件承载的视觉线索。跨模态一致性项则用于判断评论中提出的问题能否同时被商品文本和图像共同解释。这种分路召回、分路重排再融合的机制有助于在整图语义之外保留区域级证据，减少背景和整体构图的干扰，并支持对支持、部分支持与证据不足等不同状态的细粒度区分。

4 III. 实现与评估

系统实现围绕将多阶段分析结果保存为结构化对象展开。商品证据包将商品名称、描述、类别、规格、图像和评论表示为带有稳定标识符的对象。评论方面对象包含方面名称、情感、观点、原文证据、使用场景和置信度。在检索与报告阶段，系统还会将召回证据、问题意图、执行配置、方面聚合和报告归因信息分别保留为独立产物，以支持分析复现和错误定位。由此，评论抽样、问题规划、证据检索与 **claim** 归因等关键环节被统一落实为可审查的数据结构。

所提系统的主要中间产物包括商品证据包、评论方面对象、检索候选池、结构化报告以及 **manifest/replay** 等运行副产物。其中，商品证据包是构建索引和进行证据反向引用的基础，评论方面对象则作为问题规划和方面聚合的输入。检索候选池与结构化

报告用于支持最终 **claim** 的证据选择和企业决策。同时，**manifest/replay** 保存执行配置与中间结果，用于实验复现和错误分析。其中，**manifest** 记录运行配置、运行阶段与评估摘要，**replay** 则保存上一轮分析的连续性信息，使人工反馈能够回流到后续问题规划和报告精炼流程中。

当前实现包含用于查看数据集概况、商品数据标准化、索引构建、评论方面抽取以及单商品综合分析的 API。同时，系统也提供了用于执行完整 workflow、离线运行、多模态运行校验、**manifest** 评估和测试执行的脚本。这种结构使得即使实验环境发生变化，也能追踪同一输入商品产生了哪些中间产物，并能够将模型能力不足与流程设计失败区分开来。为了降低重复运行成本，系统还对 **query embedding** 与 **rerank** 结果实施签名绑定的磁盘缓存，使缓存同时受 **backend**、**model** 和候选集摘要约束，从而在复现实验时既减少重复计算，又避免不同运行配置之间的缓存污染。

从评估角度看，所提系统将检索质量与归因质量分开考察。当存在问题级相关证据标注时，检索性能可以通过 **Recall@K**、**MRR**（Mean Reciprocal Rank）和 **NDCG**（Normalized Discounted Cumulative Gain）进行评估 [5]。**Recall@K** 衡量前 **K** 个候选中是否包含正确证据，**MRR** 是正确证据首次出

现名次倒数的平均值, NDCG 则用于评价高相关证据是否被排在更靠前的位置。这些指标主要对应问题规划、分路召回和重排序设计是否真正提高了证据命中效率。

对于结构化报告, 可以计算每个 **claim** 被评论、商品文本和商品图像支持的比例。此外, 还可以通过 **citation precision**、**contradiction rate**、**modality contribution** 等指标审查报告 **claim** 的依据充分性以及各模态的贡献。这些指标不仅反映系统是否检索到相关证据, 也反映最终结论是否得到了充分支撑。本文将评估重点放在证据驱动 VOC 分析原型的稳定运行性, 以及各模块在后续消融与对照实验中的可分离性。基于这一设定, 后续可以通过移除问题规划、关闭图像路径、取消重排或关闭 **claim attribution** 等方式, 分别评估各模块对证据命中率、错误归因率和报告可审查性的影响。

图 3 展示了召回到的评论证据、商品文本证据和商品图像证据如何与结构化报告中的优势 **claim**、弱点 **claim**、改进建议 **claim** 和证据空白 **claim** 相连接。每一条连接都可以被标记为 **supported**、**partial**、**unsupported** 或 **contradicted** 等状态, 而人工审查结果又可以通过 **feedback/replay** 循环反馈到问题规划与报告精炼过程中。对于无法被商品文本或图像充分支持的评论观点, 系统不会强行生成“看似合理”的结论, 而是保留 **evidence gap** 以显式表达证据不足。当前实现已通过 166 项自动化测试, 这说明主要接口与 workflow 断言保持了一致性, 也说明该系统已经具备作为研究原型开展后续对照实验的工程稳定性。

5 IV. 结论

本文提出了 Decathlon VOC Analyzer, 这是一种用于对齐商品图文证据与用户评论的证据驱动多模态 VOC (Voice of Customer) 分析系统。所提系统先将原始商品数据标准化为可追踪的证据包, 再将用户评论抽取为方面级 VOC 对象, 随后通过问题规划、多模态候选检索、重排序、报告生成以及 **claim** 级归因, 生成结构化的商品分析结果。

本研究的核心结论是, 商品 VOC 分析不应被压缩为单阶段评论摘要任务, 而应构建为结合评论方面建模、证据问题规划、商品图文检索和证据约束生成的多阶段流程。本文系统将“评论说了什么”“商品证据能否支持”“最终结论如何建立证据对应关系”组织为彼此衔接的分析环节, 从而为证据命中、错误定位与后续对照实验提供统一接口。

同时, 本文系统保留带评分的原始评论, 并通过问题优先的星级感知抽样与低信息评论过滤, 强化了低星级反馈在评论建模中的作用。这一设计使系统能够在总体评论概括之外, 更稳定地表征与产品改进相关的问题线索。

未来研究将进一步补充跨多个商品类别的人工标注数据集, 开展问题规划、图像路径、重排序与 **claim attribution** 等模块的对照实验, 并加强更细粒度的视觉证据链接与基于人工反馈的再执行机制, 以将该系统进一步发展为可服务商品改进决策的 VOC 分析平台。

References

- [1] Patrick Lewis, Ethan Perez, Aleksandra Piktus, Fabio Petroni, Vladimir Karpukhin, Naman Goyal, Heinrich Kuttler, et al. Retrieval-augmented generation for knowledge-intensive NLP tasks. In *Advances in Neural Information Processing Systems*, volume 33, pages 9459–9474, 2020. URL <https://arxiv.org/abs/2005.11401>.
- [2] Luyu Gao, Zhuyun Dai, Panupong Pasupat, Anthony Chen, Arun Tejasvi Chaganty, Yicheng Fan, Vincent Y. Zhao, Ni Lao, Hongrae Lee, Da-Cheng Juan, and Kelvin Guu. RARR: Researching and revising what language models say, using language models. In *Proceedings of the 61st Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers)*, pages 16477–16508, 2023. doi: 10.18653/v1/2023.acl-long.910. URL <https://doi.org/10.18653/v1/2023.acl-long.910>.
- [3] Alec Radford, Jong Wook Kim, Chris Hallacy, Aditya Ramesh, Gabriel Goh, Sandhini Agarwal, Girish Sastry, Amanda Askell, Pamela Mishkin, Jack Clark, Gretchen Krueger, and Ilya Sutskever. Learning transferable visual models from natural language supervision. In *Proceedings of the 38th International Conference on Machine Learning*, pages 8748–8763. PMLR, 2021. URL <https://arxiv.org/abs/2106.00284>.




Figure 3: 证据归因与评估闭环。报告主张被映射到评论、商品文本和商品图像证据；评估模块同时衡量检索质量和生成主张的证据支撑质量。

//proceedings.mlr.press/v139/radford21a.html.

- [4] Yu Liu, Duantengchuan Li, Kaili Wang, Zhuoran Xiong, Fobo Shi, Jian Wang, Bing Li, and Bo Hang. Are LLMs good at structured outputs? a benchmark for evaluating structured output capabilities in LLMs. *Information Processing & Management*, 61 (5):103809, 2024. doi: 10.1016/j.ipm.2024.103809. URL <https://doi.org/10.1016/j.ipm.2024.103809>.

- [5] Saibo Geng, Martin Josifoski, Maxime Peyrard, and Robert West. Grammar-constrained decoding for structured NLP tasks without finetuning. In *Proceedings of the 2023 Conference on Empirical Methods in Natural Language Processing*, pages 10932–10952, 2023. doi: 10.18653/v1/2023.emnlp-main.674. URL <https://doi.org/10.18653/v1/2023.emnlp-main.674>.

- [6] Shunyu Yao, Jeffrey Zhao, Dian Yu, Nan Du, Izhak Shafran, Karthik Narasimhan, and Yuan Cao. ReAct: Synergizing reasoning

and acting in language models, 2023. URL <https://arxiv.org/abs/2210.03629>.

- [7] NVIDIA Developer Blog. An easy introduction to multimodal retrieval-augmented generation, 2024. URL <https://developer.nvidia.com/blog/an-easy-introduction-to-multimodal-retrieval-augmented-generation/>.

- [8] NVIDIA Developer Blog. Build ai-ready knowledge systems using essential multimodal rag capabilities, 2024. URL <https://developer.nvidia.com/blog/build-ai-ready-knowledge-systems-using-5-essential-multimodal-rag-capabilities/>.

- [9] Manuel Faysse, Hugues Sibille, Tony Wu, Bilel Omrani, Gautier Viaud, Celine Hudelot, and Pierre Colombo. ColPali: Efficient document retrieval with vision language models, 2024. URL <https://arxiv.org/abs/2407.01449>.

- [10] Maria Pontiki, Dimitris Galanis, John Pavlopoulos, Harris Papageorgiou, Ion

- Androutsopoulos, and Suresh Manandhar. SemEval-2014 task 4: Aspect based sentiment analysis. In *Proceedings of the 8th International Workshop on Semantic Evaluation*, pages 27–35, 2014. doi: 10.3115/v1/S14-2004. URL <https://aclanthology.org/S14-2004/>.
- [11] Qdrant. Pdf retrieval at scale: Search engineering with multi-stage retrieval, 2024. URL <https://qdrant.tech/documentation/tutorials-search-engineering/pdf-retrieval-at-scale/>.
- [12] Qdrant. Multi-vector search and multi-stage retrieval course, 2024. URL <https://qdrant.tech/blog/multi-vector-search-course/>.
- [13] Christopher D. Manning, Prabhakar Raghavan, and Hinrich Schütze. *Introduction to Information Retrieval*. Cambridge University Press, 2008. URL <https://nlp.stanford.edu/IR-book/>.